

FIAP – Pós-Tech em IA para Devs

Tech Challenge – Fase 1

Deteccção de Câncer do Colo do Útero

utilizando Algoritmos de Machine Learning Supervisionado

Relatório Técnico

Grupo 88

Gilberto Cunha - RM 372315

Gustavo Denobi - RM 373072

Thiago Garbulha - RM 372499

Victor Arruda - RM 373454

4 de maio de 2026

Resumo

Este relatório descreve a construção de um sistema de apoio ao diagnóstico precoce do câncer do colo do útero baseado em *Machine Learning* supervisionado. A solução foi desenvolvida sobre o *dataset Cervical Cancer (Risk Factors)* disponibilizado pelo UCI Machine Learning Repository, que reúne 858 registros clínicos de pacientes do Hospital Universitario de Caracas (Venezuela). São apresentadas as estratégias de pré-processamento adotadas para lidar com valores ausentes, inconsistências e forte desbalanceamento de classes; a justificativa para a escolha de cinco algoritmos de classificação (Regressão Logística, Random Forest, XGBoost, KNN e SVM); e a discussão crítica dos resultados sob a ótica de uma triagem oncológica, em que a sensibilidade (*recall* para a classe positiva) é a métrica mais relevante. O modelo **XGBoost** apresentou o melhor desempenho global, com AUC de teste igual a **0,9367** e *recall* de **0,88** para a classe “com câncer”, sendo recomendado como ferramenta de apoio – nunca substituição – à decisão médica.

Palavras-chave: Câncer cervical; *Machine Learning*; Classificação; XGBoost; Triagem clínica; Dados desbalanceados.

Sumário

1	Introdução	4
1.1	Problema e objetivo	4
1.2	Estrutura do relatório	4
2	Descrição do <i>Dataset</i>	4
2.1	Características notáveis dos dados	5
3	Análise Exploratória dos Dados	5
3.1	Inspeção inicial do <i>DataFrame</i>	6
3.2	Estatísticas descritivas e balanceamento	7
3.3	Boxplot	8
3.4	Histograma	10
3.5	Heatmap de correlação	12
4	Estratégias de Pré-processamento	14
4.1	Remoção de duplicatas	14
4.2	Conversão de tipos e tratamento do caractere “?”	14
4.3	Remoção de colunas não informativas	15
4.4	Verificação de regras de negócio	15
4.5	Deteção de <i>outliers</i> (IQR e Z-Score)	16
4.6	<i>Feature engineering</i> : imputação por regra	17
4.7	Imputação estatística	17
4.8	Separação em treino, teste e padronização	17
4.9	Tentativa de <i>oversampling</i> (SMOTENC)	18
5	Modelos Utilizados e Justificativas	19
5.1	Regressão Logística	19
5.2	Random Forest	19
5.3	XGBoost	20
5.4	K-Nearest Neighbors (KNN)	20
5.5	Support Vector Machine (SVM)	20
6	Resultados e Interpretação	20
6.1	Escolha da métrica	20
6.2	Comparativo dos modelos	21
6.3	Curva ROC dos modelos	21
6.4	Interpretação dos resultados	22
6.5	Configuração final do modelo recomendado	23

7	Discussão Crítica e Conclusão	23
7.1	O modelo pode ser usado na prática?	23
7.2	Limitações do estudo	24
7.3	Conclusão	24

1 Introdução

O câncer do colo do útero é uma das principais causas de morte por câncer entre mulheres no mundo, embora seja altamente prevenível quando detectado precocemente por meio de exames de rastreamento. Em hospitais universitários, com volume crescente de pacientes e exames, o tempo médico para análise inicial é cada vez mais escasso. Nesse cenário, sistemas de apoio ao diagnóstico baseados em IA podem acelerar a triagem e direcionar a atenção clínica para os casos mais críticos.

Este trabalho atende ao Tech Challenge da Fase 1 do curso de Pós-Tech em IA para Devs (FIAP), cujo escopo solicita o desenvolvimento de uma solução inicial de *Machine Learning* para diagnóstico clínico a partir de dados estruturados, contemplando exploração, pré-processamento, modelagem e avaliação crítica do modelo final.

1.1 Problema e objetivo

Problema. Dado um conjunto de fatores de risco – demográficos, hábitos de vida e histórico médico – prever, de forma binária, se uma paciente apresenta resultado positivo na *biópsia*, exame considerado padrão-ouro para o diagnóstico do câncer do colo do útero.

Objetivo. Construir um classificador supervisionado capaz de servir como ferramenta de **triagem** – isto é, indicar pacientes com maior probabilidade de biópsia positiva, otimizando o tempo médico sem substituir a avaliação clínica.

1.2 Estrutura do relatório

A Seção 2 descreve o *dataset* e seus atributos. A Seção 3 apresenta a análise exploratória. A Seção 4 detalha as estratégias de pré-processamento adotadas. A Seção 5 discute os modelos selecionados e suas justificativas. A Seção 6 apresenta os resultados quantitativos e sua interpretação clínica. Por fim, a Seção 7 traz a discussão crítica e a conclusão.

2 Descrição do *Dataset*

Foi utilizado o conjunto de dados *Cervical Cancer (Risk Factors)* disponibilizado pelo UCI Machine Learning Repository¹, coletado no Hospital Universitario de Caracas. O *dataset* contém **858 registros** e **36 atributos**, distribuídos nos seguintes grupos:

¹<https://archive.ics.uci.edu/dataset/383/cervical+cancer+risk+factors>

- **Demográficos:** idade, número de parceiros sexuais, idade da primeira relação, número de gestações;
- **Tabagismo:** indicador de fumante, anos fumando, maços por ano;
- **Contracepção:** uso de contraceptivos hormonais e DIU (com tempo de uso);
- **DSTs:** indicadores de diversas doenças sexualmente transmissíveis e contagem total de diagnósticos;
- **Diagnósticos prévios:** câncer, CIN, HPV;
- **Variáveis-alvo:** *Hinselmann*, *Schiller*, *Citology* e ***Biopsy***.

Embora o *dataset* forneça quatro variáveis-alvo relacionadas a exames cervicais distintos, optou-se por utilizar *Biopsy* como variável-alvo do estudo, por ser o **padrão-ouro** para o diagnóstico definitivo de câncer cervical. As demais (*Hinselmann*, *Schiller*, *Citology*) foram mantidas como *features*, funcionando como indícios fornecidos pelos demais exames.

2.1 Características notáveis dos dados

- **Valores ausentes:** representados pelo caractere “?”, com origem em recusas dos pacientes em responder por motivos de privacidade. Algumas colunas (*STDs: Time since first/last diagnosis*) chegam a ter mais de 90% de valores ausentes.
- **Tipos heterogêneos:** apesar de todas as *features* serem numéricas (quantitativas ou binárias), o *parser* original carregou várias colunas como *string* devido à presença do caractere “?”.
- **Forte desbalanceamento:** após o tratamento inicial, **93,5%** dos casos são negativos para *Biopsy* e apenas **6,5%** positivos.
- **Registros duplicados:** 23 linhas duplicadas foram identificadas e removidas.

3 Análise Exploratória dos Dados

A exploração inicial teve três objetivos:

- (i) entender a distribuição individual de cada *feature*;
- (ii) mapear a presença de valores ausentes e inconsistências;
- (iii) quantificar a relação das *features* com a variável-alvo.

3.1 Inspeção inicial do *DataFrame*

A primeira ação foi carregar o CSV com pandas e inspecionar as primeiras linhas via `df.head()`, exibido (parcialmente) no Quadro 1. Já nessa primeira visualização foi possível detectar dois sintomas:

- (i) a presença do caractere “?” como marcador de ausência (linha 3, coluna `First sexual intercourse`);
- (ii) a heterogeneidade de tipos (colunas que deveriam ser numéricas foram lidas como texto).

Listing 1: Saída parcial de `df_original.head()` - primeiras 5 linhas e 8 colunas representativas.

1		Age	N. parceiros	Idade 1a relacao	N. gestacoes	Smokes	Smokes(yrs)	...	Biopsy
2	0	18	4.0	15.0	1.0	0.0	0.0	...	0
3	1	15	1.0	14.0	1.0	0.0	0.0	...	0
4	2	34	1.0	?	1.0	0.0	0.0	...	0
5	3	52	5.0	16.0	4.0	1.0	37.0	...	0
6	4	46	3.0	21.0	4.0	0.0	0.0	...	0
7	[5 rows x 36 columns]								

O que esse *DataFrame* nos diz? O conjunto possui **858 linhas e 36 colunas**. Em seguida, montou-se um segundo *DataFrame* de *resumo* (Tabela 1) agregando, por coluna: tipo do dado, número de valores únicos, quantidade de NaN e exemplos de valores. Esse resumo guiou todo o pré-processamento subsequente, pois evidenciou que praticamente todas as colunas haviam sido importadas como `string` por causa do caractere “?”, e que algumas (STDs: Time since first/last diagnosis) tinham mais de 90% de ausências.

Tabela 1: *DataFrame* de resumo (extrato com 5 colunas representativas).

Coluna	Tipo	Únicos	NaN	Exemplos
Age	int64	44	0	13, 14, 15, 16, 17
Number of sexual partners	str	13	0	?, 1.0, 10.0, 15.0
Hormonal Contraceptives (years)	str	41	0	?, 0.0, 0.08, 0.16
STDs: Time since first diagnosis	str	19	0	?, 1.0, 2.0, 3.0
Biopsy	int64	2	0	0, 1

Por fim, a função `df_tratado.describe()` foi aplicada após a conversão para tipos numéricos, gerando estatísticas de tendência central, dispersão e quartis. A Tabela 2 resume as colunas mais relevantes e revela características marcantes do *dataset*: média de idade **27,0 anos**, média de **2,5 parceiros sexuais**, distribuições fortemente

concentradas em zero para tabagismo e DSTs, e prevalência baixa de diagnósticos prévios de câncer (média de $Dx:Cancer = 0,022$, ou seja, 2,2% das pacientes).

Tabela 2: Estatísticas descritivas (extrato de `describe()`).

Coluna	count	mean	std	min	max
Age	835	27,02	8,48	13	84
Number of sexual partners	810	2,55	1,68	1	28
First sexual intercourse	828	17,02	2,82	10	32
Num of pregnancies	779	2,30	1,46	0	11
Smokes	822	0,15	0,36	0	1
Smokes (years)	822	1,25	4,14	0	37
Hormonal Contraceptives	732	0,65	0,48	0	1
Dx:Cancer	835	0,022	0,145	0	1

Interpretação. A coluna `count` mostra quantos valores não-nulos cada *feature* possui após a conversão – a diferença em relação ao total (835 após remoção de duplicatas) representa exatamente os “?” que se transformaram em NaN. As colunas `mean/std` explicitam que a população do estudo é majoritariamente jovem, com hábitos de risco relativamente baixos – o que torna os poucos casos positivos ainda mais valiosos do ponto de vista de modelagem.

3.2 Estatísticas descritivas e balanceamento

A Tabela 3 apresenta a distribuição da variável-alvo *Biopsy* após a remoção de duplicatas. A predominância de casos negativos confirma a natureza de **problema desbalanceado** e justifica o uso de métricas como *recall* e AUC, em vez da *accuracy*.

Tabela 3: Balanceamento da variável-alvo *Biopsy*.

Classe	Registros	Percentual
0 – Sem câncer	781	93,5%
1 – Com câncer	54	6,5%
Total	835	100%

A inspeção das estatísticas descritivas mostrou que a maioria das *features* binárias possui média próxima de zero – isto é, a população do estudo é composta majoritariamente por pacientes **sem** a condição indicada (não fumantes, sem DST, sem diagnóstico prévio etc.). Isso aumenta a sensibilidade do modelo aos poucos casos positivos existentes, reforçando a necessidade de bom tratamento das classes minoritárias.

3.3 Boxplot

O boxplot é uma visualização que sintetiza, em um único gráfico, a **mediana**, os **quartis** e os **possíveis outliers** de uma variável numérica. A caixa cobre o intervalo interquartil (Q_1 a Q_3), a linha central representa a mediana, os “bigodes” se estendem até $1,5 \cdot \text{IQR}$ e os pontos além desse limite são classificados como *outliers*. A Figura 1 apresenta o boxplot de todas as colunas numéricas do *dataset* após a conversão de tipos.




Figura 1: Boxplot de todas as colunas numéricas do *dataset*.

Como ler este boxplot?

- Colunas **quantitativas** (Age, Number of sexual partners, First sexual intercourse, Num of pregnancies) apresentam caixas visíveis, indicando dispersão real. Nota-se a presença de *outliers* em Age (pacientes com mais de 50 anos) e em Number of sexual partners (alguns casos com mais de 10 parceiros, com máximo de 28).
- Colunas como Smokes (years), Hormonal Contraceptives (years) e IUD (years) têm a caixa esmagada perto de zero porque **a maior parte dos pacientes informa zero**, mas existem alguns valores muito altos (de 15 a 37) que aparecem como *outliers*.
- Praticamente todas as **colunas binárias** (por exemplo, STDs:HIV, Dx:Cancer, Biopsy) aparecem como uma linha colada em 0 com um ponto isolado em 1 – isso confirma que se trata de variáveis 0/1 e ao mesmo tempo evidencia o **forte desbalanceamento**.


Por que esse gráfico foi importante? Foi a partir do boxplot que decidiu-se:

- (i) separar as *features* em dois grupos (*quantitativas* e *binárias*), aplicando `StandardScaler` apenas nas quantitativas;
- (ii) analisar *outliers* apenas nas colunas quantitativas, já que “*outlier*” não faz sentido em uma variável 0/1;
- (iii) não remover *outliers* extremos, pois eles podem ser exatamente os sinais clínicos discriminativos.

3.4 Histograma

Como complemento ao boxplot, foi gerado um **histograma** para cada coluna (Figura 2). Enquanto o boxplot mostra estatísticas resumidas, o histograma mostra a **forma da distribuição**.

Histograma de Todas as Colunas

**Figura 2:** Histograma de todas as colunas numéricas do *dataset*.

Os histogramas confirmaram três padrões:

- Age e First sexual intercourse possuem distribuição aproximadamente normal, com leve assimetria à direita;
- Number of sexual partners e Num of pregnancies apresentam distribuição *discreta* concentrada nos primeiros valores;
- As demais colunas são fortemente **assimétricas à direita**, com massa concentrada em zero – típico de hábitos pouco frequentes em saúde pública.

3.5 Heatmap de correlação

Para quantificar a relação linear entre as *features* foi gerado um *heatmap* da matriz de correlação de Pearson, exibido na Figura 3. Cada célula representa o coeficiente de correlação $r \in [-1; +1]$ entre as duas variáveis correspondentes; cores quentes (vermelho) indicam correlação positiva forte, cores frias (azul) indicam correlação fraca ou negativa. A diagonal principal, naturalmente, é sempre 1 (uma variável correlaciona-se perfeitamente com ela mesma).




Figura 3: Heatmap de correlação de Pearson entre todas as *features* do *dataset*.

Principais leituras do *heatmap*.

- **Cluster clínico (canto inferior direito).** As colunas Hinselmann, Schiller, Citology e Biopsy apresentam correlações moderadas a altas entre si (por exemplo, $r = 0,65$ entre Hinselmann e Schiller; $r = 0,55$ entre Hinselmann e Biopsy). Isso é esperado: são quatro exames que detectam o mesmo desfecho. *Por isso a remoção dessas colunas foi testada e descartada* – elas concentram boa parte do sinal preditivo.
- **Cluster de hábitos.** Smokes, Smokes (years) e Smokes (packs/year) apresentam correlações fortes entre si ($r \geq 0,72$). O mesmo ocorre com IUD / IUD (years) ($r = 0,75$) e Hormonal Contraceptives / Hormonal Contraceptives (years) ($r = 0,44$). Apesar da redundância parcial, optou-se por mantê-las porque trazem informação complementar (presença vs intensidade da exposição).

- **Cluster de DSTs.** As colunas `STDs (number)`, `STDs:condylomatosis` e `STDs: Number of diagnosis` formam um bloco vermelho intenso, típico de agregações de eventos raros que acabam sendo descritas por múltiplas variáveis correlacionadas.
- **Sinal disperso para Biopsy.** As correlações individuais de cada *feature* com `Biopsy` são em geral baixas em módulo ($|r| < 0,2$), com exceção das variáveis-alvo irmãs. Isso indica que o sinal clínico para `Biopsy` está **distribuído em múltiplas features** simultaneamente, e não em uma única variável dominante. Essa característica favorece modelos de *ensemble* (Random Forest, XGBoost), que conseguem capturar interações não-lineares entre múltiplas *features* simultaneamente.

4 Estratégias de Pré-processamento

O pipeline de pré-processamento foi desenhado para lidar com três desafios principais do *dataset*:

- (i) valores ausentes representados por “?”;
- (ii) colunas com quase 100% de ausência;
- (iii) forte desbalanceamento da variável-alvo.

Cada decisão tomada é justificada a seguir.

4.1 Remoção de duplicatas

A primeira etapa foi a identificação e remoção de linhas duplicadas. O *dataset* continha **23 registros duplicados**, eliminados via `drop_duplicates`. Após essa etapa, o conjunto passou a ter **835 registros**.

Por quê? Manter duplicatas inflaria artificialmente o peso de certas observações durante o treinamento, podendo levar a um *overfitting* sutil em padrões que não se repetem naturalmente.

4.2 Conversão de tipos e tratamento do caractere “?”

As colunas originalmente importadas como `string` foram processadas para:

1. Remover espaços e caracteres invisíveis (`\xa0`, `\t`);

2. Substituir os valores não numéricos (“?”) por NaN;
3. Converter o tipo da coluna para float64/int64 utilizando `pd.to_numeric`.

Por quê? Essa conversão é pré-requisito para visualizações (*boxplot*, histograma), cálculo de correlação e treinamento de modelos como Regressão Logística, Random Forest, XGBoost, KNN e SVM, que exigem entrada numérica.

4.3 Remoção de colunas não informativas

Foram removidas quatro colunas do *dataset*, conforme a Tabela 4.

Tabela 4: Colunas removidas e justificativa.

Coluna	Justificativa
STDs: Time since first diagnosis	91,7% dos registros estavam ausentes; imputar geraria sinal artificial.
STDs: Time since last diagnosis	91,7% dos registros ausentes (mesmo caso).
STDs:cervical condylomatosis	Coluna <i>constante</i> (apenas zeros e NaN); após imputação, ficaria com 100% de zeros, não agregando informação.
STDs:AIDS	Mesmo caso da coluna anterior – variância zero.

Por quê? Colunas com variância zero ou cardinalidade única não contribuem para a discriminação das classes; mantê-las apenas adiciona ruído e custo computacional.

4.4 Verificação de regras de negócio

Antes de qualquer imputação, foi feita uma **tentativa de normalizar o *dataset*** a partir de *regras de negócio* – ou seja, restrições lógicas que toda paciente deveria respeitar pela própria semântica das colunas. A ideia é detectar **contradições internas** no preenchimento do registro, que apontariam para erros de coleta. Por exemplo, se a coluna *Smokes* indica que a paciente **não** fuma, é logicamente impossível ela ter *Smokes (packs/year) > 0* ou *Smokes (years) > 0*: *quem não fuma, não fuma nenhum maço por ano*.

Foram codificadas quatro regras desse tipo, cobrindo as colunas mais propensas a inconsistência, conforme a Tabela 5.

Tabela 5: Regras de negócio testadas para detecção de registos inconsistentes.

Regra	Condição lógica
Tabagismo	$\text{Smokes} = 0 \text{ e } (\text{Smokes (years)} > 0 \text{ ou } \text{Smokes (packs/year)} > 0)$
Contraceção hormonal	$\text{Hormonal Contraceptives} = 0 \text{ e } \text{Hormonal Contraceptives (years)} > 0$
DIU	$\text{IUD} = 0 \text{ e } \text{IUD (years)} > 0$
DSTs	$\text{STDs} = 0 \text{ e qualquer coluna específica de DST com valor } > 0$

Resultado. *Nenhum* registo inconsistente foi encontrado para nenhuma das quatro regras – o *dataset* do UCI passou **integralmente** no teste de coerência interna. Essa verificação serviu, portanto, como *guard rail* de qualidade: confirma que as inconsistências do *dataset* se restringem a valores *ausentes* (?), não a valores *contraditórios*. As regras foram mantidas no código como mecanismo de defesa para futuras versões do conjunto de dados.

4.5 Detecção de *outliers* (IQR e Z-Score)

Consideração inicial: o conceito de *outlier* em dados médicos. É importante destacar, antes de qualquer cálculo, que **a noção estatística de *outlier* é particularmente delicada em dados médicos**. Em estatística geral, um *outlier* é um valor “raro o suficiente para ser considerado erro”. Em medicina, no entanto, **praticamente qualquer valor é possível**: uma paciente pode realmente ter 84 anos, ter 28 parceiros sexuais ao longo da vida, fumar há 37 anos ou ter 11 gestações. Esses casos são raros, mas não fisiologicamente impossíveis – e, no contexto de uma triagem oncológica, frequentemente são exatamente os **casos de maior risco clínico**, cujo sinal preditivo não deve ser descartado.

Por essa razão, a postura adotada foi: *realizar a identificação de outliers como exercício diagnóstico para entender a distribuição dos dados, mas não removê-los do dataset*.

Tentativa de identificação. A detecção foi aplicada apenas nas colunas **quantitativas** – variáveis binárias, por definição, não apresentam *outliers*. Foram comparados dois métodos clássicos:

- **IQR (*Interquartile Range*)**: flagueia valores fora de $[Q_1 - 1,5 \cdot IQR; Q_3 + 1,5 \cdot IQR]$.
- **Z-Score**: flagueia valores com $|z| > 3$.

O comparativo entre os dois métodos revelou **discordância em 9 das 10 colunas** quantitativas. O IQR foi excessivamente sensível a distribuições assimétricas (em colunas como `Smokes (packs/year)`, 14,7% das amostras foram marcadas como *outlier*); o Z-Score, por assumir normalidade, é menos eficaz com distribuições fortemente concentradas em zero. A única coluna em que ambos concordaram foi `Num of pregnancies`, com 10 *outliers* identificados.

Decisão final. *Não remover outliers.* Como argumentado acima, valores extremos (idade muito alta, muitos parceiros sexuais, longo tempo de tabagismo, múltiplas gestações) podem ser exatamente os sinais discriminativos de risco que o modelo precisa aprender. Removê-los reduziria o sinal positivo disponível e, em testes preliminares, prejudicou as métricas finais. A tentativa de identificação serviu então como **validade exploratória** da distribuição – e não como critério de exclusão.

4.6 Feature engineering: imputação por regra

Antes da imputação estatística, aplicou-se um conjunto de regras de negócio para preencher NaN de forma *determinística* quando a coluna principal indicava ausência da condição. Por exemplo, se `Smokes = 0` e `Smokes (years) = NaN`, o NaN foi substituído por 0, já que “não fuma” implica logicamente “zero anos fumando”. As mesmas regras foram aplicadas para `Hormonal Contraceptives`, `IUD` e `STDs`.

Por quê? Substituir esses valores pela média ou moda introduziria informação espúria; a regra de negócio respeita a semântica do dado.

4.7 Imputação estatística

Os valores ausentes restantes foram imputados com `SimpleImputer` do `scikit-learn`, com estratégia distinta para cada tipo de *feature*, conforme a Tabela 6.

Tabela 6: Estratégia de imputação por tipo de *feature*.

Tipo	Estratégia	Justificativa
Binária	<code>most_frequent</code> (moda)	Garante valores em {0, 1}
Quantitativa	<code>mean</code> (média)	Preserva a tendência central

4.8 Separação em treino, teste e padronização

Os dados foram divididos em **70% treino** (584 registros) e **30% teste** (251 registros) com `train_test_split` estratificado pela variável-alvo, de modo a preservar a

proporção de classes em ambos os subconjuntos.

A padronização foi aplicada apenas nas *features* quantitativas, via `ColumnTransformer`:

Listing 2: Pipeline de padronização seletiva.

```
1 preprocessor = ColumnTransformer(transformers=[
2     ('scaler', StandardScaler(), columnas_quantitativas),
3     ('binary', 'passthrough', columnas_binarias)
4 ])
5 X_train_scaled = preprocessor.fit_transform(X_train)
6 X_test_scaled = preprocessor.transform(X_test)
```

Por quê? Aplicar `StandardScaler` em colunas binárias quebraria sua semântica (gerando valores diferentes de 0/1). O `passthrough` mantém essas colunas intactas, enquanto SVM, KNN e Regressão Logística se beneficiam da padronização das colunas contínuas, já que são sensíveis à escala.

4.9 Tentativa de *oversampling* (SMOTENC)

Por causa do forte desbalanceamento de classes (93,5% vs 6,5%), foi avaliado o uso de ***oversampling* sintético** para equilibrar artificialmente o conjunto de treino. A técnica escolhida foi o **SMOTENC** (*Synthetic Minority Over-sampling Technique — Nominal and Continuous*), uma versão do SMOTE adequada para *datasets* com *features* mistas (contínuas e categóricas), como é o caso. A configuração usada foi `sampling_strategy = 0,5`, elevando a classe minoritária para 50% do tamanho da majoritária (de ~38 para ~284 amostras na minoria, no conjunto de treino).

Por que essa abordagem foi descartada? Dois motivos levaram a abandonar o SMOTENC:

- (1) **Os dados sintéticos não são consistentes com a realidade clínica.** O SMOTENC interpola entre amostras existentes da minoria para gerar novos registros. Em um *dataset* médico, isso pode produzir combinações *biologicamente improváveis* – por exemplo, uma paciente com histórico de múltiplas DSTs simultaneamente combinadas com idade muito baixa, ou com tempos de exposição incompatíveis com a idade. Esses “pacientes sintéticos” não representam casos reais, e o modelo aprende padrões que não necessariamente generalizam.
- (2) **Os modelos não tiveram melhora significativa.** Após o re-treinamento de todos os cinco modelos com o conjunto sinteticamente balanceado, as métricas praticamente não se alteraram em relação à versão sem *oversampling*. Em alguns casos, o *recall* chegou inclusive a *piorar* – provável consequência do ponto

anterior. A hipótese complementar é que, com apenas 54 amostras positivas no *dataset* original, o “vizinho mais próximo” usado pelo SMOTE é muitas vezes pouco representativo, gerando interpolações ruidosas.

Decisão final. Não usar SMOTENC. O desbalanceamento foi tratado de forma mais segura via **hiperparâmetros nativos dos modelos**, sem criação de dados artificiais:

- `class_weight='balanced'` (Regressão Logística, SVM) e `'balanced_subsample'` (Random Forest);
- `scale_pos_weight` ajustado dinamicamente como $\frac{n_{neg}}{n_{pos}} \approx 14$ (XGBoost);
- **tuning de *threshold*** via curva precisão-revocação para o SVM.

Essa abordagem resolve o desbalanceamento *em tempo de treinamento*, ponderando o custo dos erros sem alterar a distribuição real dos dados, o que é considerado boa prática em *datasets* médicos.

5 Modelos Utilizados e Justificativas

Conforme orientação do Tech Challenge, foram empregadas **cinco** técnicas distintas de classificação, cobrindo famílias algorítmicas diferentes. Essa diversidade permite comparar abordagens lineares, baseadas em vizinhança, *ensembles* de árvores e modelos baseados em margem.

5.1 Regressão Logística

Por quê? É o *baseline* clássico para classificação binária em problemas clínicos: produz coeficientes interpretáveis (razão de chances) e é leve. Foram utilizadas regularização **ElasticNet** (mistura $\ell_1 + \ell_2$), `class_weight='balanced'` para mitigar o desbalanceamento e GridSearchCV sobre C e `l1_ratio`.

5.2 Random Forest

Por quê? *Ensemble* de árvores bem adequado a *datasets* pequenos e desbalanceados. Robusto a *outliers*, captura interações não-lineares e permite extrair *feature importance*. Foi utilizado `class_weight='balanced_subsample'` (mais eficaz que `balanced` em RF), com busca de hiperparâmetros otimizada para *recall*.

5.3 XGBoost

Por quê? *Gradient boosting* moderno, referência em competições de tabular ML. Suporta nativamente o tratamento de classes desbalanceadas via `scale_pos_weight` (ajustado dinamicamente para a proporção do treino). A métrica de treino foi `aucpr` (*Area Under Precision-Recall Curve*), mais informativa que `logloss` em *datasets* desbalanceados.

5.4 K-Nearest Neighbors (KNN)

Por quê? Método não paramétrico, útil como contraprova: se um modelo simples baseado em vizinhança obtiver desempenho comparável, sugere que o problema possui estrutura local. Foi utilizado `GridSearchCV` sobre k , com ponderação por distância e métrica *Manhattan*.

5.5 Support Vector Machine (SVM)

Por quê? Eficaz em espaços de alta dimensão relativamente ao número de amostras. Utilizou-se `kernel RBF`, `class_weight='balanced'` e `probability=True` para permitir o ajuste do limiar de decisão. Adicionalmente, foi realizado um **tuning de *threshold*** via `cross_val_predict`, identificando o ponto de corte ótimo segundo a curva precisão-revoação (*best threshold* = 0,1661 no treino).

6 Resultados e Interpretação

6.1 Escolha da métrica

Em uma triagem oncológica, o objetivo é **minimizar falsos negativos** – ou seja, não deixar passar uma paciente realmente doente. Por isso a métrica primária é o **recall** (sensibilidade) na classe positiva, complementado por:

- **AUC-ROC**: capacidade global de separar as duas classes em todos os *thresholds*;
- **F1-score**: equilíbrio entre precisão e *recall*, importante para evitar uma quantidade excessiva de falsos positivos (que sobrecarregaria a equipe clínica);
- **AUC CV (*cross-validation*)**: indica a estabilidade do desempenho em diferentes partições dos dados.

A *accuracy* foi descartada como métrica principal: como 93,5% das amostras são negativas, um classificador trivial que sempre retorna “não tem câncer” atingiria 93,5%

de *accuracy* sem detectar um único caso real.

6.2 Comparativo dos modelos

A Tabela 7 consolida o desempenho dos cinco modelos no conjunto de teste. Todos os valores foram obtidos com a mesma divisão treino/teste estratificada e a mesma pipeline de pré-processamento.

Tabela 7: Comparação dos modelos no conjunto de teste.

Modelo	AUC CV	Std CV	AUC Teste	Recall (1)	F1 (1)	Precision (1)
XGBoost	0,9765	$\pm 0,0202$	0,9367	0,88	0,72	0,61
Regressão Logíst.	0,9201	$\pm 0,0702$	0,9168	0,88	0,72	0,61
Random Forest	0,9672	$\pm 0,0319$	0,9138	0,88	0,70	0,58
SVM	0,9277	$\pm 0,0651$	0,8638	0,62	—	—
KNN	0,7744	$\pm 0,0818$	0,7955	0,12	0,20	0,50

6.3 Curva ROC dos modelos

A **curva ROC** (*Receiver Operating Characteristic*) compara, para diversos limiares de decisão, a *Taxa de Verdadeiros Positivos* (*recall* para a classe positiva) contra a *Taxa de Falsos Positivos* (alarmes incorretos em pacientes saudáveis). Quanto mais a curva se aproxima do canto superior esquerdo, melhor a capacidade discriminativa do modelo. A área sob a curva (AUC) é o resumo numérico desse comportamento, sendo 1,0 o ideal e 0,5 o desempenho de um classificador aleatório.




Figura 4: Curva ROC comparativa dos cinco modelos no conjunto de teste.

Leitura da Figura 4. O **XGBoost** (verde) mantém a curva mais próxima do canto superior esquerdo em quase toda a faixa de *thresholds*, com AUC de **0,94**. **Regressão Logística** (azul, AUC 0,92) e **Random Forest** (laranja, AUC 0,91) seguem juntos, com desempenho semelhante. **SVM** (roxo, AUC 0,86) demora mais para “subir” e o **KNN** (vermelho, AUC 0,80) é o mais próximo da diagonal – ou seja, o que mais se aproxima de um chute aleatório.

6.4 Interpretação dos resultados

XGBoost: o melhor compromisso. O XGBoost apresentou **a maior AUC** no conjunto de teste (0,9367), o **maior AUC médio** em validação cruzada (0,9765) e o **menor desvio-padrão** ($\pm 0,0202$). Isso indica não apenas que o modelo é bom, mas que seu desempenho é **estável** entre diferentes partições – característica essencial para uso em produção clínica, em que as métricas precisam ser confiáveis.

Recall empatado em três modelos. XGBoost, Random Forest e Regressão Logística empatam com *recall* de 0,88 – isto é, detectaram **14 de 16** casos reais de câncer no

conjunto de teste. Para desempate, prevalecem AUC e estabilidade, ambos favoráveis ao XGBoost.

Modelos descartados.

- **SVM** apresentou *recall* de 0,62, deixando de detectar 6 dos 16 casos. Inadequado para triagem oncológica.
- **KNN** ficou com *recall* de apenas 0,12 (2 de 16 casos detectados). Inaceitável para uso clínico.

Especificidade preservada. O *recall* para a classe “sem câncer” do XGBoost foi de 0,9617, ou seja, 96% das pacientes realmente saudáveis foram classificadas corretamente. Isso é relevante para não sobrecarregar a equipe clínica com falsos alertas.

Precisão ainda limitada. A *precision* de 0,61 do XGBoost significa que, a cada 10 alertas de câncer, aproximadamente 6 serão verdadeiros positivos e 4 serão falsos positivos. Em uma ferramenta de **triagem** isso é aceitável – o custo de um falso positivo (exame adicional) é muito menor do que o de um falso negativo (câncer não detectado).

6.5 Configuração final do modelo recomendado

Listing 3: Hiperparâmetros do XGBoost selecionado.

```
1 XGBClassifier(  
2     scale_pos_weight=neg/pos,      # ~14, calculado dinamicamente  
3     n_estimators=300,  
4     learning_rate=0.05,           # menor = mais conservador  
5     max_depth=4,                  # reduz overfitting  
6     subsample=0.8,                # amostragem por arvore  
7     colsample_bytree=0.8,          # amostragem de features  
8     min_child_weight=5,            # exige mais amostras por folha  
9     random_state=42,  
10    eval_metric='aucpr'            # AUC-PR e mais informativa  
11 )
```

7 Discussão Crítica e Conclusão

7.1 O modelo pode ser usado na prática?

Sim, mas como ferramenta de apoio. O modelo final atende aos requisitos de uma triagem inicial: identifica 88% dos casos positivos com 96% de especificidade e oferece

probabilidades que podem ser usadas para priorizar a fila de exames complementares. Porém, **não deve ser usado para emitir diagnóstico isolado**. A biópsia continua sendo o exame definitivo, e o(a) médico(a) sempre deve ter a palavra final.

Recomenda-se o seguinte fluxo:

1. Coleta dos fatores de risco da paciente em sistema clínico;
2. Modelo retorna probabilidade estimada de biópsia positiva;
3. Casos com probabilidade acima de um limiar definido pela equipe clínica (por exemplo, 0,3) recebem **prioridade** no encaminhamento para colposcopia e biópsia;
4. Médico revisa o caso e toma a decisão final.

7.2 Limitações do estudo

- **Tamanho amostral pequeno:** 835 registros, com apenas 54 positivos. Para um sistema em produção, mais dados são essenciais.
- **Viés geográfico:** dados coletados em um único hospital na Venezuela. A generalização para outras populações deve ser validada.
- **Ausência de calibração:** as probabilidades do XGBoost podem não estar bem calibradas; *isotonic regression* ou *Platt scaling* poderiam ser aplicados em trabalhos futuros.
- **Ausência de SHAP/feature importance neste relato:** a interpretabilidade local foi preparada na pipeline (*permutation_importance*), mas não foi gerada formalmente para esta versão do relatório. Recomenda-se sua inclusão em iterações futuras.

7.3 Conclusão

O trabalho demonstrou um pipeline completo de *Machine Learning* aplicado a um problema clínico real, contemplando todas as etapas exigidas pelo Tech Challenge: exploração de dados, pré-processamento robusto, treinamento de múltiplos modelos, avaliação por métricas adequadas e discussão crítica do uso prático. O modelo **XGBoost** foi selecionado por combinar a maior AUC, o maior *recall* entre os melhores candidatos e a maior estabilidade em validação cruzada, tornando-se uma opção sólida como ferramenta de **apoio à triagem oncológica**. Reforça-se que a solução foi

concebida para *auxiliar* a equipe médica, e não para substituí-la: a decisão final clínica **sempre** cabe ao(à) profissional responsável.

Referências

- [1] Fernandes, K., Cardoso, J. S., & Fernandes, J. *Cervical Cancer (Risk Factors) Data Set*. UCI Machine Learning Repository, 2017. Disponível em: <https://archive.ics.uci.edu/dataset/383/cervical+cancer+risk+factors>.
- [2] Pedregosa, F. et al. *Scikit-learn: Machine Learning in Python*. Journal of Machine Learning Research, v. 12, p. 2825–2830, 2011.
- [3] Chen, T., & Guestrin, C. *XGBoost: A Scalable Tree Boosting System*. In: Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2016, p. 785–794.
- [4] Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. *SMOTE: Synthetic Minority Over-sampling Technique*. Journal of Artificial Intelligence Research, v. 16, p. 321–357, 2002.